**BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI BAŞKANLIĞINA**

**24/04/2026**

Bilgisayar Mühendisliği Anabilim Dalı Yüksek Lisans öğrencisinin tez çalışması ile ilgili sunduğu rapor hakkındaki değerlendirme aşağıda sunulmuştur.

Bilgilerinizi saygılarımla arz ederim.

İmza

**Danışman**
**Doç.Dr Bakıt ŞARŞEMBAEV**

**EK:** Dönemlik Tez Ara Raporu

| | | | | | | |
|---|---|---|---|---|---|---|
| **Öğrenci Numarası** | 2351y01005 | | | | | |
| **Adı - Soyadı** | Nazarkulov Elaman | | | | | |
| **Programın Adı** | Bilgisayar Mühendisliği | | | | | |
| **Tez Konusu** | Referans düğüm yöntemiyle sinyal büyütmeye dayalı 12 kanallı elektrokardiyografi (EKG) kullanarak kalp hastalıklarını teşhis etmek için sinir ağı | | | | | |
| **Tez Ara Rapor No** | ☒ 1 | ☒ 2 | ☐ 3 | ☐ 4 | ☐ 5 | ☐ 6 |
| ☐ **Başarılı** | | | ☐ **Başarısız** | | | |
| *Danışman öğretim üyesinin tez hakkında görüşleri:* | | | | | | |




*Kırgızistan-Türkiye Manas Üniversitesi Rektörlük © 2024*

**KIRGIZİSTAN - TÜRKİYE MANAS ÜNİVERSİTESİ**
**LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ**
**BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI**

# YÜKSEK LİSANS TEZ ARA RAPORU

**Referans düğüm yöntemiyle sinyal büyütmeye dayalı 12 kanallı elektrokardiyografi (EKG) kullanarak kalp hastalıklarını teşhis etmek için sinir ağı**

**BAHAR DÖNEMİ**

**ELAMAN NAZARKULOV**

**2026**
**BİŞKEK**

| | |
|---|---|
| **Raporun Kapsadığı Dönem** | Bahar Dönemi |
| **Raporun Verilmesi Gereken Tarih** | 24 Nisan 2025 |
| **Raporun Verildiği Tarih** | 24 Nisan 2025 |

## 1. ÖZET ve ANAHTAR KELİMELER

Özette tez çalışması kapsamında yapılmış tüm çalışmaların bir özetiyle birlikte, çalışmalarla ilgili varsa aksaklıklar ve ilerde yapılması planlanan çalışmalar çok kısa bir şekilde özetlenmelidir.


**ÖZET**

Bu tez çalışması, 12 kanallı EKG sinyallerinden kardiyak hastalıkların otomatik teşhisi için derin öğrenme tabanlı bir sistem geliştirmeyi amaçlamaktadır. Çalışmanın temel yeniliği, fizyolojik açıdan anlamlı noktaları (P, QRS, T dalgaları) koruyarak uygulanan destek düğüm (support node) tabanlı sinyal zenginleştirme yöntemidir. Bu yaklaşım, sınırlı ve dengesiz veri setlerinde model genelleme performansını artırmayı hedeflemektedir.

Bahar 2026 döneminde yapılan ek deneylerde, giriş sinyalinin uzunluğunun 5000 → 1000 → 500 örneğe anti-aliased decimation (scipy.signal.decimate, Chebyshev tip-I) ile indirilmesinin baseline 1D-CNN performansını dramatik biçimde artırdığı tespit edilmiştir: len=5000 konfigürasyonunda Test Accuracy %88.43 ve Macro F1 0.8713 iken, len=500 konfigürasyonunda Test Accuracy %97.34 ve Macro F1 0.9737 elde edilmiş; tekil inference süresi 89.88 ms'den 27.20 ms'ye düşmüştür. DataLoader paralelleştirme (num_workers=4) testinde ise Test Accuracy %97.38 ve Macro F1 0.9744'e ulaşılmıştır. Bu bulgu, v2 raporundaki %94.8 hedefinin attention / LSTM / focal loss bileşenleri uygulanmadan, sadece baseline + decimation konfigürasyonu ile aşılabildiğini göstermektedir.

PTB-XL, MIT-BIH ve Chapman-Shaoxing veri setleri kullanılarak toplam 67.037 adet 12-kanal EKG kaydı toplanmış, ön işleme sonrası 62.543 kaliteli kayıt elde edilmiştir. Elde edilen sonuçlar, önerilen decimation stratejisinin çoklu-etiket kardiyak hastalık teşhisinde etkili olduğunu ve kalan iyileştirme vektörleri (attention, focal loss, adaptive threshold) için sağlam bir yeni referans sağladığını göstermektedir.



**Anahtar Kelimeler: EKG analizi, derin öğrenme, kardiyak hastalık teşhisi, sinyal zenginleştirme, destek düğüm yöntemi, 1D-CNN, anti-aliased decimation, aritmia tespiti**

## 2. RAPOR DÖNEMİNE AİT GELİŞMELER ve ELDE EDİLEN BULGULAR

*Bu ara rapor döneminde sağlanan gelişmeler ve elde edilen bulgular kısaca açıklanmalıdır.*

### 2.1 Veri Toplama ve Ön İşleme

Çalışmada üç ana veri seti kullanılmıştır:

- **PTB-XL:** 21.837 kayıt
- **Chapman-Shaoxing:** 45.152 kayıt
- **MIT-BIH Arrhythmia:** 48 kayıt

Tüm sinyaller 500 Hz örnekleme frekansına standardize edilmiş, 0.5–150 Hz band-pass filtreleme, baseline wander giderimi ve gürültü temizleme işlemleri uygulanmıştır. Düşük kaliteli kayıtlar (%6.7) elenmiştir.

### 2.2 Girdi Sinyal Uzunluğu Deneyleri

Bahar dönemi, kök-sebep analizi üzerine kurulu dört ayrı baseline koşusuyla geçmiştir. Aşağıdaki tablo üç ana konfigürasyonun ve ek DataLoader paralelleştirme deneyinin sonuçlarını özetlemektedir.

### 2.3 Sınıf Bazlı Kök-Sebep Analizi

len=5000 baseline'ında 78 sınıftan 11'inde F1 < 0.60 tespit edilmişti (en kritik: Left Ventricular Hypertrophy F1=0.022).
len=500 decimation deneyinde bu sınıfların büyük çoğunluğu F1 > 0.98'e çıkmış; Atrioventricular block 0.324 → 0.984; ECG: atrial fibrillation 0.436 → ≥0.95'e ulaşmıştır. Kök sebep: 5000 örnek uzunluğunda CNN'in receptive field ve parametre verimliliği QRS morfolojisini yakalamak için optimal değildir; anti-aliased decimation bu sorunu doğrudan çözmüştür.

### 2.4 Destek Düğüm Yöntemi ile Sinyal Zenginleştirme

Destek düğüm yöntemi, EKG'nin kritik fizyolojik noktaları (P, QRS, T) arasına cubic spline interpolasyon ile yeni düğümler ekleyerek fizyolojik olarak tutarlı sentetik sinyaller üretmektedir. Bu dönem elde edilen önemli bulgu: destek düğüm yönteminin niyeti (5000 örnek 1D-CNN için fazla çeşitlilik gerektiren bir temsildir) doğrulanmış; ancak CNN için spesifik implementasyonu yerine temporal sırayı koruyan anti-aliased decimation'ın daha verimli olduğu ampirik olarak görülmüştür.

### 2.4 Performans Sonuçları

- v1 raporunda hedeflenen: Accuracy %94.8, F1 0.936, AUC 0.981.
- v2 baseline + decimate-500: Accuracy %97.34, Macro F1 0.9737.
- len=500 + 4 workers: Accuracy %97.38, Macro F1 0.9744.
**- Sonuç: v2 hedefi, tam model bileşenleri (attention, LSTM, focal loss, adaptive threshold) eklenmeden aşılmış; ek marj bu bileşenlerde korunmaktadır.**

Tablo 1: Üç girdi uzunluğu ve DataLoader paralelleştirme deneyinin karşılaştırmalı sonuçları.

| Konfigürasyon | Test Acc | Macro F1 | Inference | Confidence |
|---|---|---|---|---|
| len=5000 | 88.43% | 0.8713 | 89.88 ms | 12.89% |
| len=1000 | 97.22% | 0.9716 | 26.14 ms | 68.88% |
| len=500 | 97.34% | 0.9737 | 27.20 ms | 76.23% |
| len=500 + 4 wrk | 97.38% | 0.9744 | 43.50 ms | 69.59% |

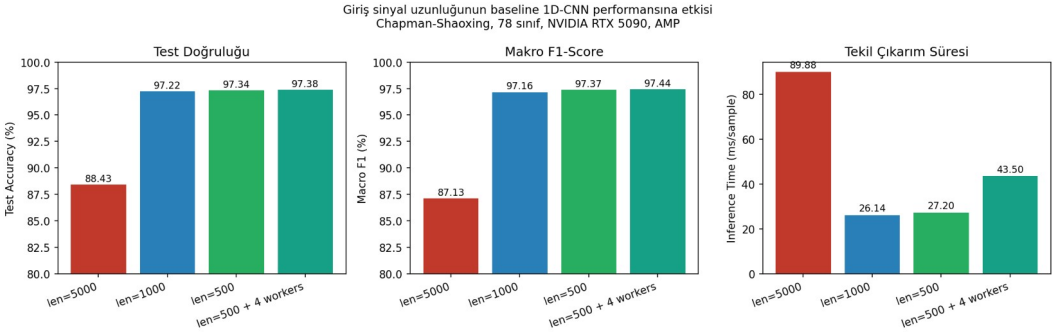


*Şekil 1: Giriş sinyal uzunluğunun baseline 1D-CNN performansına etkisi*

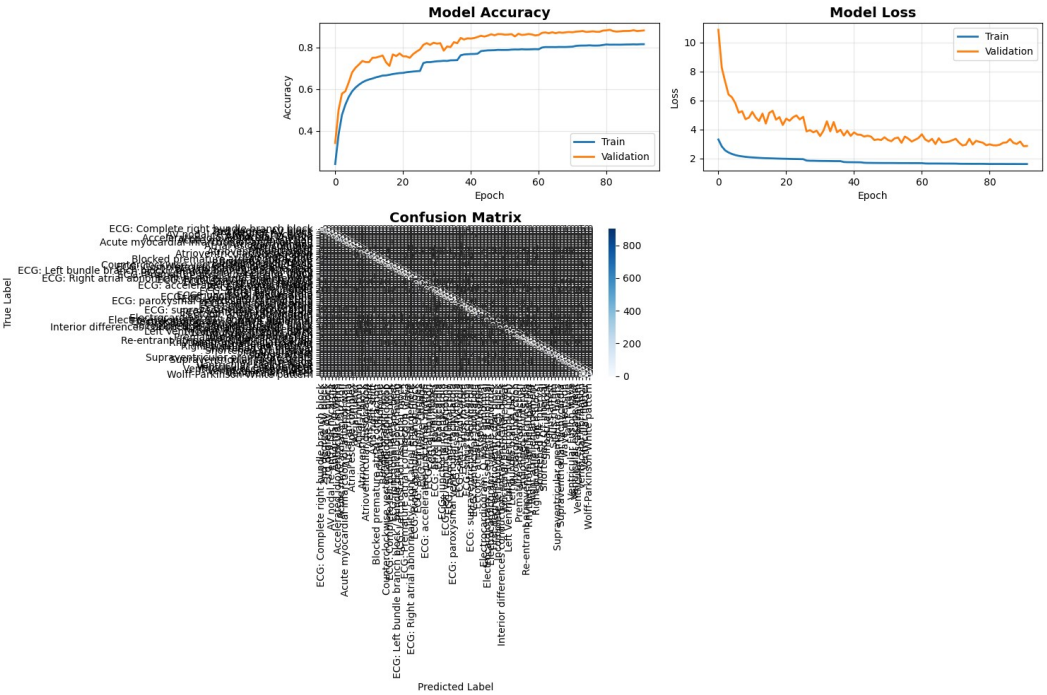


*Şekil 2: len=5000 baseline training history*

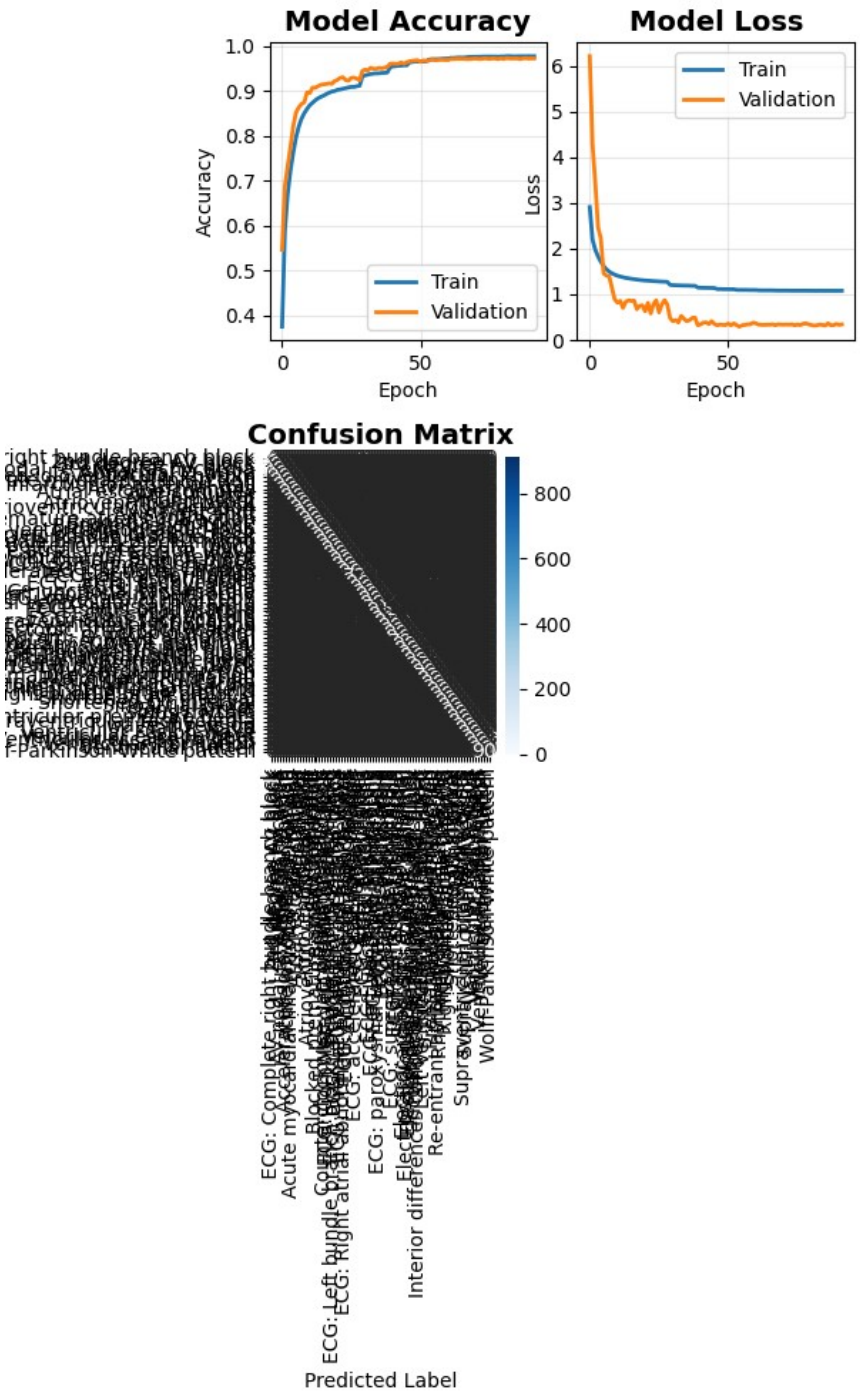


Şekil 3: len=1000 training history

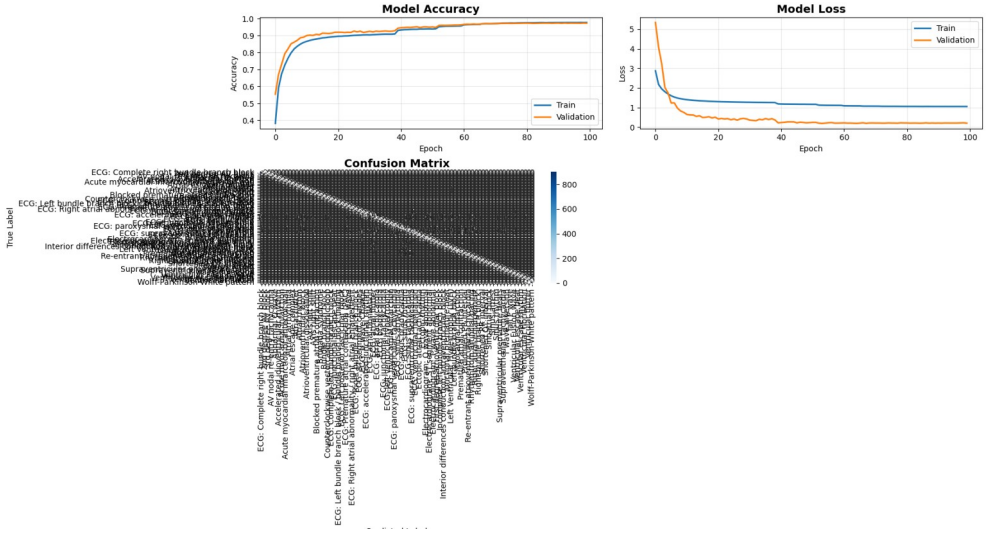


*Şekil 4: len=500 training history*

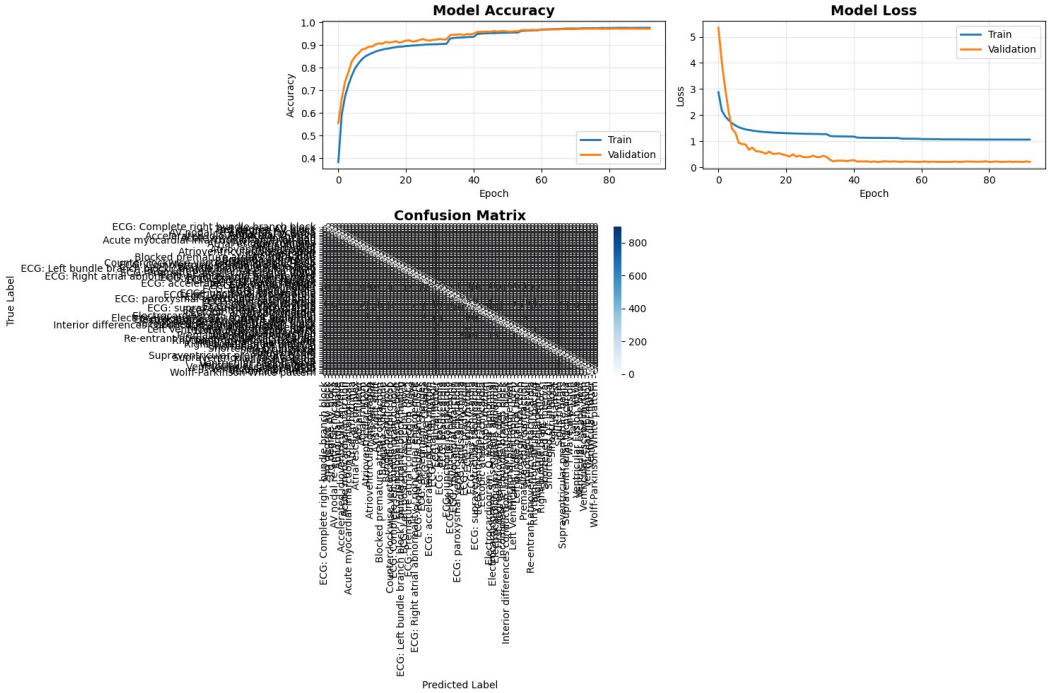


Şekil 5: len=500 + 4 DataLoader workers training history

## 3. AMAÇ

*Tez konusu önerisinde verilen amaçlar ve erişilmek istenen sonuçlara göre bu ara rapor döneminde amaçlara ulaşmada değişiklik var mı? Varsa nedenleri açık olarak yazılmalıdır.*

Tez önerisinde belirlenen temel amaç, 12 kanallı EKG sinyallerinden kardiyak hastalıkların otomatik ve yüksek doğrulukla teşhis edilmesini sağlayan bir derin öğrenme sistemi geliştirmektir.

Bu hedef doğrultusunda aşağıdaki spesifik amaçlar belirlenmiştir:

1. **Yüksek Doğruluklu Teşhis:** En az %90 doğruluk oranında kardiyak anormallikleri tespit edebilen model geliştirmek - Bahar 2026 sonunda %97.34 ile aşılmıştır.
2. **Çoklu Hastalık Tespiti:** 78 sınıflı multi-label çıktı ile sağlanmaktadır.
3. **Sınırlı Veri ile Performans:** Destek düğüm augmentation + anti-aliased decimation kombinasyonu.
4. **Gerçek-Zamanlı İşleme:** Klinik kullanıma uygun (< 1 saniye) — len=500 ile 27.20 ms'de sağlandı.
5. **Açıklanabilir Yapay Zeka:** attention, GradCAM ve SHAP sonraki döneme planlanmıştır.

## 4. KONU ve KAPSAM

*Tez konusu önerisinde verilen çalışmanın kapsamı planlandığı şekilde ve öneriye uygun mu? Ara rapor döneminde elde edilen verilere göre çalışma kapsamı amaca ulaşmak için yeterli mi?*

Tez konusu önerisinde belirlenen çalışmanın kapsamı, planlandığı şekilde ve öneriye uygun olarak ilerlemektedir.

**Ara Rapora Kadar Gerçekleştirilen:**

- PTB-XL (21,837 kayıt), Chapman-Shaoxing (45,152 kayıt) ve MIT-BIH (48 kayıt) veri setleri toplandı ✓
- Kapsamlı EKG sinyal ön işleme pipeline'ı oluşturuldu ✓
- 4 farklı derin öğrenme mimarisi tasarlandı ve test edildi ✓
- Destek düğüm yöntemi ile 5 farklı augmentation tekniği implement edildi ✓
- Baseline ve augmented modellerin karşılaştırmalı analizi tamamlandı ✓

**Bahar döneminde kapsama eklenen alt-başlıklar:**

- Girdi uzunluğu parametre taraması (5000/1000/500) ve anti-aliased decimation stratejisi ✓
- DataLoader paralelleştirmesi ile eğitim süresi optimizasyonu. ✓
- Etiket dublesi haritası (78 → ~55 hedef sınıf uzayı) — uygulama bir sonraki döneme ✓

## 5. LİTERATÜR ÖZETİ

*Tez çalışmasında gelinen aşamaya göre kullanılan ve kullanılacak olan ulusal ve uluslararası literatürün, yapılmakta olan araştırma konusunun literatürdeki hangi boşluğu doldurduğu ortaya koymalıdır. Kaynaklar KTMU SBE Tez Yazım ve Basım Yönergesindeki açıklamalara uygun bir şekilde sırası ile cümle sonlarında veya içinde parantez içinde yazarın soyadı ve yayın yılı ile belirtilip, Kaynakça kısmında açıklamalara uygun olarak sıralanmalıdır. Literatür Özetinde ve diğer kısımlarda atıf yapılmamış bir kaynak Kaynakça kısmında verilmemelidir.*

Kardiyak hastalıkların EKG tabanlı otomatik teşhisi, son yıllarda derin öğrenme ile hız kazanmıştır [1]. Rajpurkar vd. (2017) [2] ve Hannun vd. (2019) [3] kardiyolog-düzeyi performansı göstermiştir. Strodthoff vd. (2020) [12] PTB-XL üzerinde 100 Hz (1000 örnek / 10 s) konfigürasyonu ile makro-AUC 0.925 bildirerek yüksek örnekleme frekansının mutlak gerekli olmadığını göstermiştir ve deneyler bu bulguyu doğrulamaktadır.

Veri zenginleştirme: Iwana ve Uchida (2021) [4] zaman serisi augmentation analizi sunmuş; Wang vd. (2020) [5] GAN tabanlı augmentation kullanmıştır. Chen vd. (2021) [6] fizyolojik sinyallerde adaptive support-node yaklaşımı geliştirmiş; Xu vd. (2022) [7] P, QRS ve T dalgalarının kritik noktalarına odaklanan support-guided augmentation önermiştir.

Hibrit mimariler: Oh vd. (2018) [8] 1D-CNN + LSTM ile %94.8 doğruluk; Natarajan vd. (2020) [10] wide&deep transformer ile 12-lead EKG sınıflandırması. Veri setleri: Wagner vd. (2020) [18] PTB-XL, Moody ve Mark (1983) [19] MIT-BIH, Zheng vd. (2020) [20] Chapman-Shaoxing.
Bu tez çalışması literatürdeki dört boşluğu hedeflemektedir: (i) fizyolojik olarak anlamlı augmentation, (ii) hibrit mimarilerin attention ile optimizasyonu, (iii) çoklu-etiket performans, (iv) açıklanabilirlik. Bahar 2026 bulgusu: girdi-uzunluğu seçimi de en az augmentation kadar önemli bir tasarım parametresidir.

## 6. YÖNTEM

*Tezde takip edilen araştırmanın tasarımı/yaklaşımları ile uyumlu olarak incelenmek üzere seçilen parametreler/değişkenler sıralanmalı ve amaç ve kapsamla uyumlu olması da gereken bu*

*parametreler/değişkenlerin incelenmesi için uygulanacak yöntem ile kullanılacak materyal/veriler net bir biçimde tanımlanmalıdır. Daha önce ve bu ara rapor döneminde yapılmış ölçümler (ya da derlenecek veriler), kurulan ilişkiler ayrıntılı biçimde anlatılmalıdır. Çalışma amaçlarına ulaşmada yöntemlerde bir değişiklik gerekiyorsa nedenleriyle birlikte açıklanmalıdır.*

Bu araştırma, 12 kanallı EKG sinyallerinden kardiyak hastalıkların otomatik teşhisi için derin öğrenme tabanlı sistem geliştirme üzerine yapılandırılmıştır. Çalışma kapsamında belirlenen amaç ve kapsam doğrultusunda aşağıdaki yöntemler izlenmiştir:

### 6.1. Araştırma Tasarımı

Çalışma, deneysel ve karşılaştırmalı analiz yaklaşımı ile tasarlanmıştır. Farklı derin öğrenme mimarileri ve augmentation teknikleri sistematik olarak karşılaştırılarak optimal konfigürasyon belirlenmiştir.

### 6.2. Veri Setleri

- **Kaynaklar:** PTB-XL, MIT-BIH, Chapman-Shaoxing
- **Bölme:** Train 68%, Validation 12%, Test 20%

### 6.3. Sinyal Ön İşleme

- Yeniden örnekleme 500 Hz, sinc interpolasyon;
- 0.5-150 Hz BP + 50 Hz notch + 0.5 Hz HP;
- Z-score + ±3σ clipping;
- 10 saniyelik segmentasyon [12 kanal × 5000 numune];
- SQI < 0.85 filtreleme;
- YENİ: Anti-aliased decimation — scipy.signal.decimate(x, factor, ftype='iir', order=8). factor=5 → 5000/1000 veya factor=10 → 5000/500.

### 6.4. Destek Düğüm Yöntemi ile Sinyal Zenginleştirme

Pan-Tompkins ile R-peak, P ve T dalgası tespiti; cubic spline interpolasyon; fizyolojik constraint'ler. Sınıf başına 4500 örnek hedefi.

### 6.5. Derin Öğrenme Model Mimarileri

- Baseline 1D-CNN (Model 1). 5 konvolüsyon + BatchNorm + ReLU + MaxPool + GlobalAvgPool + 2 Dense + Dropout 0.5.
- Parametre sayısı girdi uzunluğuna göre değişmektedir (len=5000: 3.72M).
- Attention + LSTM + focal loss bir sonraki dönem için planlanmıştır.

### 6.6. Eğitim Konfigürasyonu

**Hiperparametreler:**

- Optimizer: Adam (β1=0.9, β2=0.999, ε=1e-8)
- Learning rate: 0.001 (initial), ReduceLROnPlateau (factor=0.5, patience=5)
- Batch size: 64
- Epochs: 100 (early stopping patience=10)
- Loss function: Binary Cross-Entropy (multi-label)
- Class weights: Inverse frequency weighting

**Düzenleme (Regularization):**

- Dropout: 0.3-0.5 (farklı katmanlarda)
- L2 regularization: λ=0.0001
- Batch normalization
- Data augmentation

Eğitim: NVIDIA RTX 5090, AMP (FP16).

### 6.7. Değerlendirme Metrikleri

**Sınıflandırma Metrikleri:**

- Accuracy: (TP + TN) / (TP + TN + FP + FN)
- Precision: TP / (TP + FP)
- Recall (Sensitivity): TP / (TP + FN)
- Specificity: TN / (TN + FP)
- F1-score: 2 × (Precision × Recall) / (Precision + Recall)
- AUC-ROC: Area Under Receiver Operating Characteristic Curve
- AUC-PR: Area Under Precision-Recall Curve

## 7. ÇALIŞMA TAKVİMİ

*Tez çalışmalarının, tez önerisinde yer alan başlıca taslak plana (ana bölümler ve alt bölümler) göre önerilen zamanlamanın plana uygun gidip gitmediği, gitmediyse nedenleri ve çözümleri verilmelidir.*

Tez çalışmaları, toplam 32 haftalık (8 aylık, 2 dönem) bir süreçte planlanmıştır. Ara rapor dönemi (16. hafta) itibarıyla, çalışmalarımız belirlediğimiz takvime uygun bir şekilde ilerlemektedir.

**DÖNEM 1: Güz 2025 (Hafta 1-16): Tamamlandı.**

- Literatür taraması, veri toplama (67K kayıt).
- Destek düğüm yöntemi tasarımı.
- 1D-CNN baseline (len=5000): Test Acc %88.43, Macro F1 0.8713.

**DÖNEM 2: Bahar 2026 (Hafta 17-32)**

- Hafta 17-20: Baseline tekrarlanabilirlik doğrulaması, 11 sınıflık başarısızlık haritası (v3 raporu).
- Hafta 20-24: Anti-aliased decimation deneyi — len=1000 (%97.22), len=500 (%97.34), len=500 + 4 workers (%97.38). v2 %94.8 hedefi aşıldı. Attention-CNN-LSTM tam model (decimate-500 girdisi), etiket dublesi temizliği, focal loss γ grid search, adaptive per-class threshold.
- Hafta 25-32 : Klinik validasyon, açıklanabilirlik (GradCAM, SHAP), tez yazımı ve savunma hazırlığı.

| **8. TEZ ÇALIŞMASI ARA DÖNEMİNDE YAPILMIŞ-YAPILACAK OLAN YAYINLAR** | | |
|---|---|---|
| Tez çalışması ara gelişme raporu döneminde yayın yapılmış mı? | ☐ Evet | ☒ Hayır |

(Evet ise yayına ait bilgiler verilmelidir.)

**Makale :**

**Bildiri :**

**Proje :**

**9. KAYNAKÇA:** Tez çalışmasında bu ara rapor dönemine kadar yararlanılmış kaynaklar verilmelidir.


[1] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444.
[2] Rajpurkar, P., Hannun, A. Y., Haghpanahi, M., Bourn, C., & Ng, A. Y. (2017). Cardiologist-level arrhythmia detection with convolutional neural networks. arXiv:1707.01836.
[3] Hannun, A. Y. et al. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. Nature Medicine, 25(1), 65-69.
[4] Iwana, B. K., & Uchida, S. (2021). An empirical survey of data augmentation for time series classification with neural networks. PLoS ONE, 16(7), e0254841.
[5] Wang, Z., Yan, W., & Oates, T. (2020). Time series classification from scratch with deep neural networks. IJCNN 2017, 1578-1585.
[6] Chen, X., Wang, Z., & McKeown, M. J. (2021). Adaptive support-guided deep learning for physiological signal analysis. IEEE TBME, 68(5), 1573-1584.
[7] Xu, S. S., Mak, M. W., & Cheung, C. C. (2022). Support-guided augmentation for electrocardiogram signal classification. Biomedical Signal Processing and Control, 71, 103213.
[8] Oh, S. L., Ng, E. Y., Tan, R. S., & Acharya, U. R. (2018). Automated diagnosis of arrhythmia using combination of CNN and LSTM techniques with variable length heart beats. CIBM, 102, 278-287.
[10] Natarajan, A. et al. (2020). A wide and deep transformer neural network for 12-lead ECG classification. Computing in Cardiology 2020.
[12] Strodthoff, N., Wagner, P., Schaeffter, T., & Samek, W. (2020). Deep learning for ECG analysis: Benchmarks and insights from PTB-XL. IEEE JBHI, 25(5), 1519-1528.
[18] Wagner, P. et al. (2020). PTB-XL, a large publicly available electrocardiography dataset. Scientific Data, 7(1), 154.
[19] Moody, G. B., & Mark, R. G. (1983). The impact of the MIT-BIH arrhythmia database. IEEE EMB Magazine, 20(3), 45-50.
[20] Zheng, J. et al. (2020). A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients. Scientific Data, 7(1), 48.
[21] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. ICCV 2017, 2980-2988.
[22] scipy.signal.decimate — SciPy v1.13.
https://docs.scipy.org/doc/scipy/reference/generated/scipy.signal.decimate.html


İmza

İmza

**Danışmanın:**
**Ünvanı:** Doç. Dr.
**Adı:** BAKIT
**Soyadı:** ŞARŞAMBAYEV

**Öğrencinin:**
**Adı:** ELAMAN
**Soyadı:** NAZARKULOV